#### Министерство науки и высшего образования Российской Федерации

# ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ "МЭИ"

Институт информационных и вычислительных технологий

Кафедра математического и компьютерного моделирования

Отчёт по лабораторной работе №3 "Оценки"

> Студент: Симаков А.М. Преподаватель: Шевченко О.В.

#### 1 Постановка задачи оценивания

Пусть  $(x_n)$  - выборка, т.е. n независимых испытаний случайной величины X, имеющей функцию распределения F(x/a), зависящую от параметра a, значение которого неизвестно. Требуется оценить значение параметра a.

**Оценкой**  $\widehat{a} = \varphi(x_1, ..., x_n)$  называется функция наблюдений, используемая для приближенного определения неизвестного параметра. Значение оценки является **случайной величиной**, поскольку  $(x_1, ..., x_n)$  - случайная величина (многомерная).

#### Свойства оценок

- 1) Оценка  $\widehat{a}=\varphi(x_1,...,x_n)$  называется **состоятельной**, если при  $n\to\infty$   $\widehat{a}\to a$  по вероятности  $\forall a.$
- 2) Оценка  $\widehat{a} = \varphi(x_1, ..., x_n)$  называется **несмещенной**, если  $\forall a$   $M\widehat{a} = M\varphi(x_1, ..., x_n) = a$ .
- 3) Оценка  $\varphi^*$  называется **оптимальной**, если для неё средний квадрат ошибки  $M[\widehat{a}-a]^2=M[\varphi^*(x_1,...,x_n)-a]^2=\min M[\varphi(x_1,...,x_n)-a]^2$  минимален среди всех оценок  $(\varphi)$ .

#### Метод моментов

Пусть  $(\xi_n)$  - выборка, т.е. n независимых наблюдений над случайной величиной  $\xi_0$ .  $F(x; a_1, ..., a_r)$  - функция распределения, зависящая от неизвестных параметров  $a = (a_1, ..., a_r)$ . Требуется оценить их.

Идея: неизвестные параметры выразить через начальные моменты, а затем вместо моментов подставить несмещенные и состоятельные оценки моментов.

$$m_{1} = \int_{-\infty}^{\infty} x dF(x; a_{1}, ..., a_{r}) = f_{1}(a_{1}, ..., a_{r})$$

$$...$$

$$m_{r} = \int_{-\infty}^{\infty} x^{r} dF(x; a_{1}, ..., a_{r}) = f_{r}(a_{1}, ..., a_{r})$$

Отсюда

$$a_j = g_j(m_1, ..., m_r), \quad j \in [1, r] \cap \mathbb{N}$$

Подставив вместо моментов  $m_1,...,m_r$  их оценки  $\widehat{m_1},...,\widehat{m_r}$  получим

$$\widehat{a}_j = g_j(\widehat{m}_1, ..., \widehat{m}_r), \quad \widehat{m}_k = \frac{1}{n} \sum_{i=1}^n \xi_i^k, \quad j, k \in [1, r] \cap \mathbb{N}$$

#### Метод максимального правдоподобия

Пусть  $(\xi_n)$  - выборка.  $q(x_i,a)$  - распределение i-ого наблюдения,  $a=(a_1,...,a_r)$  - неизвестный параметр.  $p_{\xi}(x;a)=\prod_{i=1}^n q(x_i,a)$  - распределение выборки  $x=(x_n)$ . Функция  $p_{\xi}(x;a)$ , как функция параметра a, при фиксированном x, называется функцией правдоподобия.

**Оценкой максимального правдоподобия**  $a^*$  параметра a называется такое значение, при котором функция правдоподобия  $p_{\xi}(x;a)$  достигает максимума:

$$a^*: p_{\xi}(x; a) = \max_a p_{\xi}(x; a)$$

Если максимум достигается во внутренней точке области определения функции, то  $a^*$  удовлетворяет системе уравнений:

$$\frac{\partial \log p_{\xi}(x;a)}{\partial a_i}\Big|_{a=a^*} = 0, \quad i \in [1,r] \cap \mathbb{N}$$

Использование логарифма не изменяет точки максимума, но упрощает выкладки при независимых наблюдениях. Оценка  $a^* = a^*(x)$  является функцией наблюдений x. Чтобы подчеркнуть случайность аргумента, напишем  $a^*(\xi)$ .

# Метод порядковых статистик

Метод основан на оценках  $\zeta_p$  при разных p. Пусть  $(\xi_n)$  - выборка с F(x;a), зависящей от параметра a, значение которого требуется оценить. Выберем p так, чтобы квантиль  $x_p$  зависела от параметра:

$$x_p = f(a)$$

Тогда получим

$$a = g(x_p)$$

Вместо  $x_p$  подставим выборочную квантиль  $\zeta_p = \xi_{[np]+1},$  в результате чего получим состоятельную оценку

$$\widehat{a} = g(\xi_{[np]+1})$$

Таким же образом можно построить оценки и для многомерного параметра.

#### Статистическая задача

По выборке  $(x_n)$  для случайной величины  $X \sim \mathcal{R}[0,a]$  оценить параметр a. Сравним три оценки

#### Метод моментов

$$\widehat{a_1} = \frac{2}{n} \sum_{i=1}^{n} x_i$$

Метод максимального правдоподобия (исправлена смещённость)

$$\widehat{a_2} = \frac{n+1}{n} \max x_i$$

## Метод порядковых статистик

$$\widehat{a}_3 = 2 \cdot \widehat{x}_{0.5} = x_k + x_{k+1},$$

где  $\widehat{x}_{0.5} = \frac{x_k + x_{k+1}}{2}$ - выборочная квантиль порядка 0.5, т.е. **выборочная медиа- на**.  $x_k$  - член вариационного ряда (полагаем n=2k).

Точность этих оценок можно сравнить теоретически и экспериментально (статистически).

Все три оценки несмещённые, что можно проверить методами теории вероятностей. Определим дисперсии оценок.

$$D\widehat{a}_1 = D\frac{2}{n}\sum_{i=1}^n x_i = \frac{4}{n^2}\sum_{i=1}^n Dx_i = \frac{4}{n^2}nDx_i = \frac{4na^2}{12n^2} = \frac{a^2}{3n}$$

Определим функцию распределения статистики  $\max x_i$ 

$$F(t) = P\{\max x_i < t\} = \prod_{i=1}^n P\{x_i < t\} = \left(\frac{t}{a}\right)^n, \quad t \in [0, a]$$

Тогда плотность распределения

$$p(t) = \frac{dF}{dt} = \frac{n}{a} \left(\frac{t}{a}\right)^{n-1}, \quad t \in [0, a]$$

Далее

$$M\widehat{a}_2 = M\left[\frac{n+1}{n}\max x_i\right] = \frac{n+1}{n}\int_0^a t\frac{n}{a}\left(\frac{t}{a}\right)^{n-1}dt = a$$

$$M\widehat{a}_{2}^{2} = M \left[ \frac{n+1}{n} \max x_{i} \right]^{2} = \left( \frac{n+1}{n} \right)^{2} \int_{0}^{a} t^{2} \frac{n}{a} \left( \frac{t}{a} \right)^{n-1} dt = \left( \frac{n+1}{n} \right)^{2} \frac{n}{n+2} a^{2}$$

Тогда

$$D\widehat{a}_2 = M\widehat{a}_2^2 - M^2\widehat{a}_2 = \frac{a^2}{n(n+1)}$$

Для вычисления  $D\widehat{a_3}$  используем теорему Крамера, которая говорит, что выборочная p-квантиль имеет дисперсию, приблизительно равную  $\frac{1}{n}\frac{p(1-p)}{f^2(x_p)}$ , где  $x_p$  - истинная p-квантиль, f(x) - плотность распределения выборки. При n=2k статистика

$$\frac{x_k + x_{k+1}}{2} \equiv m$$

является выборочной медианой  $(p=0.5), f(x_{0.5})=1/a, \hat{a_3}=2m.$  Следовательно,

$$D\widehat{a}_3 = Dm = 4\frac{1}{n} \frac{\frac{1}{2}\frac{1}{2}}{\left(\frac{1}{a}\right)^2} = \frac{a^2}{n}$$

Имеем

$$D\widehat{a}_1 = \frac{a^2}{3n}, \quad D\widehat{a}_2 = \frac{a^2}{n(n+1)}, \quad D\widehat{a}_3 = \frac{a^2}{n}$$

Следовательно,  $\widehat{a_2}$  - наиболее точная оценка,  $\widehat{a_3}$  - наименее.

## Статистическое сравнение оценок

Далеко не всегда удается аналитически вычислить дисперсию оценки. Как экспериментально определить, какой из оценок пользоваться?

Характеристиками разброса значений  $(a_k)$  оценки  $\widehat{a}$  будем считать размах

$$w = \max a_i - \min a_i$$

и среднеквадратичное отклонение (СКО)

$$S_a = \sqrt{\frac{1}{k-1} \sum_{i=1}^k (a_i - \overline{a})^2}, \quad \overline{a} = \frac{1}{k} \sum_{i=1}^k a_i$$

# 2 Результаты экспериментов

Приведу характеристики оценок  $\widehat{a_1}$ ,  $\widehat{a_2}$ ,  $\widehat{a_3}$  для выборки  $(x_n): x_n \sim \mathcal{R}[0,1]$  разного объёма  $(n \in \{10,40,160\})$  в виде таблиц. Таблица для  $\widehat{a_1}$ 

n	CKO	MIN	MAX	Разброс
10	0.162	0.598	1.226	0.628
40	0.121	0.725	1.207	0.482
160	0.042	0.941	1.117	0.176


# Таблица для $\widehat{a_2}$


n	CKO	MIN	MAX	Разброс
10	0.061	0.901	1.097	0.196
40	0.025	0.912	1.025	0.113
160	0.006	0.984	1.006	0.022


## Таблица для $\widehat{a_3}$

n	CKO	MIN	MAX	Разброс
10	0.224	0.366	1.299	0.933
40	0.178	0.661	1.344	0.683
160	0.079	0.896	1.228	0.332


По таблицам можно видеть, что  $\widehat{a_2}$  - наиболее точная оценка,  $\widehat{a_3}$  - наименее. Также приведу графики.







По графикам видно, что у  $\widehat{a_3}$  разброс больше, чем у  $\widehat{a_2}$ . Графически сравним СКО трёх наших оценок.



Очевидна правильность наших предыдущих слов.

# 3 Задание для самостоятельной работы

Сравнить статистически на выборках объема n=10 две оценки: оценку максимального правдоподобия и медианную оценку

- 1) среднего нормального распределения
- 2) параметра показательного распределения.

#### Оценка среднего нормального распределения

Оценка максимального правдоподобия

$$\widehat{a}_2 = \frac{1}{n} \sum_{i=1}^n x_i$$

Медианная оценка

$$\widehat{a}_3 = \widehat{x}_{0.5} = \frac{x_k + x_{k+1}}{2}$$

Рассмотрим 20 выборок размера 10, распределенных по закону  $\mathcal{N}(0,1)$ . Получим следующие характеристики оценок:


Таблица для  $\widehat{a_2}$ 

n	CKO	MIN	MAX	Разброс
10	0.332	-0.689	0.527	1.216

Таблица для  $\widehat{a_3}$ 

n	CKO	MIN	MAX	Разброс
10	0.404	-0.725	0.783	1.508

Также приведу график



Сравнивая СКО и разбросы делаем вывод, что оценка  $\widehat{a}_2$  более точная, чем  $\widehat{a}_3$ .

## Оценка параметра показательного распределения

Оценка максимального правдоподобия

$$\widehat{a}_2 = \left[\frac{1}{n} \sum_{i=1}^n x_i\right]^{-1}$$

Медианная оценка

$$\widehat{a_3} = \frac{\log 2}{x_k + x_{k+1}}$$

Рассмотрим 20 выборок размера 10, распределенных по закону  $\mathcal{E}(5)$ . Получим следующие характеристики оценок:


Таблица для  $\widehat{a_2}$ 

n	CKO	MIN	MAX	Разброс
10	2.574	3.947	15.251	11.304

Таблица для  $\widehat{a_3}$ 

n	CKO	MIN	MAX	Разброс
10	3.834	2.724	17.172	14.448

Также приведу график



Сравнивая СКО и разбросы делаем вывод, что оценка  $\widehat{a}_2$  более точная, чем  $\widehat{a}_3$ .

#### 4 Конкретная индивидуальная задача

Количество производственных травм за время T является случайной величиной с распределением  $\mathcal{P}(\lambda T)$ . Поквартальные данные за k лет оказались  $(x_n)$ , n=4k. Если за год число травм оказывается равным N и более, завод подвергается штрафу и проверке. Оценить вероятность этого события в следующем году. Поквартальные данные получить моделированием; среднее значение принять m.

$$k = 5$$
,  $N = 40$ ,  $m = 8$ ,  $n = 4k = 20$ 

1 год =4 квартала Так как мы рассматриваем количество травм за год, то T=4.

#### Решение

По наблюдениям  $(x_n)$  (n=20) над случайной величиной X с распределением  $\mathcal{P}(\lambda T)$  оценить вероятность

$$P\{\xi \ge N\} = 1 - P\{\xi < N\} = 1 - P\{\xi < 40\}$$

Так как  $\xi$ - случайная величина с распределением  $\mathcal{P}(4\lambda)$ , то

$$P\{\xi < 40\} = \sum_{i=1}^{40} \frac{(4\lambda)^k}{k!} e^{-4\lambda}$$

Построим оценку максимального правдоподобия для параметра  $\lambda$ . Для величины с распределением  $\mathcal{P}(\lambda)$  имеем

$$P\left\{x=k\right\} = \frac{\lambda^k}{k!}e^{-\lambda}$$

Тогда для выборки получим

$$p_{\xi}(x;\lambda) = \prod_{i=1}^{n} \frac{\lambda^{x_i}}{x_i!} e^{-\lambda} = \frac{\lambda^{\sum_{i=1}^{n} x_i}}{\prod_{i=1}^{n} x_i!} e^{-\lambda n}$$

Найдём максимум функции правдоподобия:

$$\log \left[ \frac{\lambda^{\sum_{i=1}^{n} x_i}}{\prod_{i=1}^{n} x_i!} e^{-\lambda n} \right] = -\lambda n + \log \lambda \sum_{i=1}^{n} x_i - \log \left[ \prod_{i=1}^{n} x_i! \right]$$

$$\implies \frac{d}{d\lambda} \left( -\lambda n + \log \lambda \sum_{i=1}^{n} x_i - \log \left[ \prod_{i=1}^{n} x_i! \right] \right) = -n + \frac{1}{\lambda} \sum_{i=1}^{n} x_i = 0$$

$$\implies \widehat{\lambda} = \frac{1}{n} \sum_{i=1}^{n} x_i$$

Получим значение  $\widehat{\lambda}$  по исходным данным

$$X = (4, 4, 13, 7, 2, 9, 7, 5, 8, 10, 2, 5, 9, 11, 6, 6, 7, 8, 12, 9) \implies \hat{\lambda} = \frac{144}{20} = 7.2$$

Тогда получим следующую оценку для вероятности

$$\widehat{p} = P\left\{\xi \ge 40\right\} = 1 - \sum_{i=1}^{40} \frac{(4 \cdot 7.2)^k}{k!} e^{-4 \cdot 7.2} \approx 0.028$$

В случае, если бы мы искали вероятность по известному значению m=8, то получили бы следующее значение

$$\tilde{p} = P\{\xi \ge 40\} = 1 - \sum_{i=1}^{40} \frac{(4 \cdot 8)^k}{k!} e^{-4 \cdot 8} \approx 0.096$$